

Comparación del Árbol K-d y Búsqueda Cuadrática

Introducción

En este experimento se comparó el desempeño de dos métodos de búsqueda en un conjunto de datos multidimensionales:

1. Árbol K-d: Una estructura de datos eficiente para dividir y buscar puntos en espacios de múltiples dimensiones.
2. Búsqueda cuadrática (todos contra todos): Un enfoque directo que compara cada punto con todos los demás, con una complejidad $O(n^2)$.

El objetivo fue evaluar el tiempo de búsqueda de cada método conforme se incrementa el número de datos y las dimensiones.


Experimento 1: Desempeño con Número de Datos Variable

En este experimento se varió el número de datos de 1,000 a 100,000 en un espacio bidimensional. El tiempo de búsqueda se midió tanto para el árbol K-d como para la búsqueda cuadrática.

Resultados:

- El árbol K-d mostró una escalabilidad superior al manejar un gran número de datos.
- La búsqueda cuadrática incrementó su tiempo de manera cuadrática con el número de datos.

Esto demuestra la ventaja del árbol K-d en escenarios con grandes volúmenes de datos.




Experimento 2: Desempeño con Número de Dimensiones Variable

En este experimento se evaluó el desempeño del árbol K-d conforme se incrementó el número de dimensiones de los datos, manteniendo fijo el tamaño del conjunto en 10,000 datos.

Resultados:

- El tiempo de búsqueda en el árbol K-d aumentó con el número de dimensiones.
- A pesar de esto, sigue siendo eficiente en comparación con métodos cuadráticos.

El árbol K-d es útil para datos de baja a moderada dimensionalidad, pero su desempeño puede degradarse en dimensiones muy altas debido a la 'maldición de la dimensionalidad'.



Conclusión

Este estudio comparó el desempeño del árbol K-d y la búsqueda cuadrática en diferentes escenarios.

Conclusiones principales:

- El árbol K-d es significativamente más eficiente que la búsqueda cuadrática al manejar grandes volúmenes de datos en espacios de baja a moderada dimensionalidad.
- La búsqueda cuadrática no es práctica para grandes conjuntos de datos debido a su alta complejidad computacional.
- Conforme aumenta el número de dimensiones, el árbol K-d enfrenta limitaciones, aunque sigue siendo más eficiente que métodos no optimizados.